

# SVD

## Metody Numeryczne

dr eng. Grzegorz Fotyga

Gdańsk University of Technology  
Faculty of Electronics, Telecommunications and Informatics  
Department of Microwave and Antenna Engineering

8 czerwca 2018

# Tematy

1 Introduction

2 Operacje na wektorach


3 Ortogonalność

4 SVD

# Wstęp (1)

SVD - **Singular Value Decomposition** - Rozkład na wartości osobliwe - jeden z *najpotężniejszych* i najbardziej przydatnych algorytmów. Stosowany w niemal wszystkich obszarach inżynierii danych,. m.in.:


- data analysis, big data, compression



# Wstęp (1)

SVD - **Singular Value Decomposition** - Rozkład na wartości osobliwe - jeden z *najpotężniejszych* i najbardziej przydatnych algorytmów. Stosowany w niemal wszystkich obszarach inżynierii danych,. m.in.:


- data analysis, big data, compression
- machine learning



# Wstęp (1)

SVD - **Singular Value Decomposition** - Rozkład na wartości osobliwe - jeden z *najpotężniejszych* i najbardziej przydatnych algorytmów. Stosowany w niemal wszystkich obszarach inżynierii danych,. m.in.:


- data analysis, big data, compression
- machine learning
- gene data analysis



# Wstęp (1)

**SVD - Singular Value Decomposition** - Rozkład na wartości osobliwe - jeden z *najpotężniejszych* i najbardziej przydatnych algorytmów. Stosowany w niemal wszystkich obszarach inżynierii danych,. m.in.:


- data analysis, big data, compression
- machine learning
- gene data analysis
- model-order reduction + simulation (acoustics, electrodynamics, mechanics...)



# Wstęp (1)

**SVD - Singular Value Decomposition** - Rozkład na wartości osobliwe - jeden z *najpotężniejszych* i najbardziej przydatnych algorytmów. Stosowany w niemal wszystkich obszarach inżynierii danych, . m.in.:


- data analysis, big data, compression
- machine learning
- gene data analysis
- model-order reduction + simulation (acoustics, electrodynamics, mechanics...)
- least squares solution, matrix pseudo-inverse



# Wstęp (1)

**SVD - Singular Value Decomposition** - Rozkład na wartości osobliwe - jeden z *najpotężniejszych* i najbardziej przydatnych algorytmów. Stosowany w niemal wszystkich obszarach inżynierii danych, . m.in.:

- data analysis, big data, compression
- machine learning
- gene data analysis
- model-order reduction + simulation (acoustics, electrodynamics, mechanics...)
- least squares solution, matrix pseudo-inverse
- condition of a matrix (linear dependence)






# Wstęp (1)


SVD - **Singular Value Decomposition** - Rozkład na wartości osobliwe - jeden z *najpotężniejszych* i najbardziej przydatnych algorytmów. Stosowany w niemal wszystkich obszarach inżynierii danych, . m.in.:

- data analysis, big data, compression
- machine learning
- gene data analysis
- model-order reduction + simulation (acoustics, electrodynamics, mechanics...)
- least squares solution, matrix pseudo-inverse
- condition of a matrix (linear dependence)
- **wiele** innych...




## Wstęp (2)

- **Web searching** Search engines like Google use enormous matrices of cross-references—which pages link to which other pages, and what words are on each page. (...) But there are billions of pages out there, and storing a billion by billion matrix is trouble, not to mention searching through it.  
⇒ **Here is where SVD shines.**




## Wstęp (2)

- Skupimy się na image processing.




## Wstęp (2)

- Skupimy się na image processing.
- Czyja to **twarz**?



## Wstęp (2)

- Skupimy się na image processing.
- Czyja to **twarz**?
- Żeby odpowiedzieć na pytanie - zwiększymy dokładność kompresji. Ale dopiero za tydzień.



## Wstęp (3)

- **SVD** - stosowane zarówno do macierzy **rzeczywistych** i **urojonych**.

$$\mathbf{A} = \mathbf{U} \cdot \mathbf{\Sigma} \cdot \mathbf{V}^T$$

## Wstęp (3)

- **SVD** - stosowane zarówno do macierzy **rzeczywistych** i **urojonych**.
- Skupimy się tylko na rzeczywistych, ponieważ w tym przypadku łatwiej jest interpretować (i wizualizować) wyniki

$$\mathbf{A} = \mathbf{U} \cdot \mathbf{\Sigma} \cdot \mathbf{V}^T$$

## Wstęp (3)

- **SVD** - stosowane zarówno do macierzy **rzeczywistych** i **urojonych**.
- Skupimy się tylko na rzeczywistych, ponieważ w tym przypadku łatwiej jest interpretować (i wizualizować) wyniki
- SVD jest faktoryzacją (podobnie jak LU, QR, LDLT, Cholesky etc.)

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \quad (1)$$

$$\mathbf{A} = \mathbf{U} \cdot \mathbf{\Sigma} \cdot \mathbf{V}^T$$



## Wstęp (3)

- **SVD** - stosowane zarówno do macierzy **rzeczywistych** i **urojonych**.
- Skupimy się tylko na rzeczywistych, ponieważ w tym przypadku łatwiej jest interpretować (i wizualizować) wyniki
- SVD jest faktoryzacją (podobnie jak LU, QR, LDLT, Cholesky etc.)

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \quad (1)$$

- gdzie

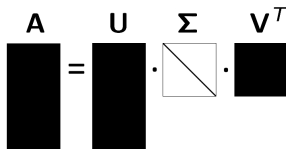
$$\mathbf{A} = \mathbf{U} \cdot \mathbf{\Sigma} \cdot \mathbf{V}^T$$

## Wstęp (3)

- **SVD** - stosowane zarówno do macierzy **rzeczywistych** i **urojonych**.
- Skupimy się tylko na rzeczywistych, ponieważ w tym przypadku łatwiej jest interpretować (i wizualizować) wyniki
- SVD jest faktoryzacją (podobnie jak LU, QR, LDLT, Cholesky etc.)

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \quad (1)$$

- gdzie
  - $\mathbf{A}$  jest  $m \times n$  macierzą

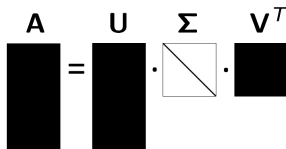

$$\mathbf{A} = \mathbf{U} \cdot \mathbf{\Sigma} \cdot \mathbf{V}^T$$

## Wstęp (3)

- **SVD** - stosowane zarówno do macierzy **rzeczywistych** i **urojonych**.
- Skupimy się tylko na rzeczywistych, ponieważ w tym przypadku łatwiej jest interpretować (i wizualizować) wyniki
- SVD jest faktoryzacją (podobnie jak LU, QR, LDLT, Cholesky etc.)

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \quad (1)$$

- gdzie
  - **A** jest  $m \times n$  macierzą
  - **U** jest  $m \times n$  **ortogonalną** macierzą

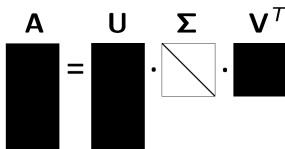


## Wstęp (3)

- **SVD** - stosowane zarówno do macierzy **rzeczywistych** i **urojonych**.
- Skupimy się tylko na rzeczywistych, ponieważ w tym przypadku łatwiej jest interpretować (i wizualizować) wyniki
- SVD jest faktoryzacją (podobnie jak LU, QR, LDLT, Cholesky etc.)

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \quad (1)$$

- gdzie
  - $\mathbf{A}$  jest  $m \times n$  macierzą
  - $\mathbf{U}$  jest  $m \times n$  **ortogonalną** macierzą
  - $\mathbf{\Sigma}$  jest  $n \times n$  **diagonalną** macierzą


$$\mathbf{A} = \mathbf{U} \cdot \mathbf{\Sigma} \cdot \mathbf{V}^T$$

## Wstęp (3)

- **SVD** - stosowane zarówno do macierzy **rzeczywistych** i **urojonych**.
- Skupimy się tylko na rzeczywistych, ponieważ w tym przypadku łatwiej jest interpretować (i wizualizować) wyniki
- SVD jest faktoryzacją (podobnie jak LU, QR, LDLT, Cholesky etc.)

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \quad (1)$$

- gdzie
  - **A** jest  $m \times n$  macierzą
  - **U** jest  $m \times m$  **ortogonalną** macierzą
  - **$\Sigma$**  jest  $n \times n$  **diagonalną** macierzą
  - **V** jest  $n \times n$  **ortogonalną** macierzą

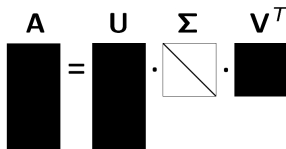
$$\mathbf{A} = \mathbf{U} \cdot \mathbf{\Sigma} \cdot \mathbf{V}^T$$

## Wstęp (3)

- **SVD** - stosowane zarówno do macierzy **rzeczywistych** i **urojonych**.
- Skupimy się tylko na rzeczywistych, ponieważ w tym przypadku łatwiej jest interpretować (i wizualizować) wyniki
- SVD jest faktoryzacją (podobnie jak LU, QR, LDLT, Cholesky etc.)

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \quad (1)$$

- gdzie
  - $\mathbf{A}$  jest  $m \times n$  macierzą
  - $\mathbf{U}$  jest  $m \times m$  **ortogonalną** macierzą
  - $\mathbf{\Sigma}$  jest  $n \times n$  **diagonalną** macierzą
  - $\mathbf{V}$  jest  $n \times n$  **ortogonalną** macierzą
  - zakładamy  $m > n$



## Wstęp (4)

$$A = U\Sigma V^T$$

The diagram illustrates the SVD decomposition  $A = U\Sigma V^T$ . Matrix  $A$  is represented by a tall black rectangle. It is equal to matrix  $U$  (a tall black rectangle), multiplied by matrix  $\Sigma$  (a square with a diagonal line from top-left to bottom-right), which is then multiplied by matrix  $V^T$  (a square black rectangle).

Jednak, zanim przejdziemy do SVD, musimy omówić parę **prostych** narzędzi, operacji.

# Operacje na wektorach

① Rozpatrzmy 2 wektory:  $\mathbf{a}$  i  $\mathbf{b} \in \mathbb{R}^3$ :

$$\mathbf{a} = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 5 \\ 4 \\ 7 \end{bmatrix}$$



# Operacje na wektorach

- ① Rozpatrzmy 2 wektory:  $\mathbf{a}$  i  $\mathbf{b} \in \mathbb{R}^3$ :

$$\mathbf{a} = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 5 \\ 4 \\ 7 \end{bmatrix}$$

- ② The *dot product* (iloczyn skalarny) w  $\mathbb{R}^3$  przestrzeni (podobnie w przestrzeni  $\mathbb{R}^n$ ):

$$\mathbf{a}^T \cdot \mathbf{b} = \mathbf{b}^T \cdot \mathbf{a} = [1, 3, 5] \begin{bmatrix} 5 \\ 4 \\ 7 \end{bmatrix} = \sum_{i=1}^3 (a_i b_i) = 1 \cdot 5 + 3 \cdot 4 + 5 \cdot 7 = 52$$

# Operacje na wektorach

- ❶ Rozpatrzmy 2 wektory:  $\mathbf{a}$  i  $\mathbf{b} \in \mathbb{R}^3$ :

$$\mathbf{a} = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 5 \\ 4 \\ 7 \end{bmatrix}$$

- ❷ The *dot product* (iloczyn skalarny) w  $\mathbb{R}^3$  przestrzeni (podobnie w przestrzeni  $\mathbb{R}^n$ ):

$$\mathbf{a}^T \cdot \mathbf{b} = \mathbf{b}^T \cdot \mathbf{a} = [1, 3, 5] \begin{bmatrix} 5 \\ 4 \\ 7 \end{bmatrix} = \sum_{i=1}^3 (a_i b_i) = 1 \cdot 5 + 3 \cdot 4 + 5 \cdot 7 = 52$$

- ❸ The *outer product* (iloczyn diadyczny) w przestrzeni  $\mathbb{R}^3$  (podobnie w  $\mathbb{R}^n$ ):

$$\mathbf{a} \cdot \mathbf{b}^T = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix} [5, 4, 7] = \begin{bmatrix} 1 \cdot 5 & 1 \cdot 4 & 1 \cdot 7 \\ 3 \cdot 5 & 3 \cdot 4 & 3 \cdot 7 \\ 5 \cdot 5 & 5 \cdot 4 & 5 \cdot 7 \end{bmatrix} = \begin{bmatrix} 5 & 4 & 7 \\ 15 & 12 & 21 \\ 25 & 20 & 35 \end{bmatrix}$$

# Operacje na wektorach

- ❶ Rozpatrzmy 2 wektory:  $\mathbf{a}$  i  $\mathbf{b} \in \mathbb{R}^3$ :

$$\mathbf{a} = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 5 \\ 4 \\ 7 \end{bmatrix}$$

- ❷ The *dot product* (iloczyn skalarny) w  $\mathbb{R}^3$  przestrzeni (podobnie w przestrzeni  $\mathbb{R}^n$ ):

$$\mathbf{a}^T \cdot \mathbf{b} = \mathbf{b}^T \cdot \mathbf{a} = [1, 3, 5] \begin{bmatrix} 5 \\ 4 \\ 7 \end{bmatrix} = \sum_{i=1}^3 (a_i b_i) = 1 \cdot 5 + 3 \cdot 4 + 5 \cdot 7 = 52$$

- ❸ The *outer product* (iloczyn diadyczny) w przestrzeni  $\mathbb{R}^3$  (podobnie w  $\mathbb{R}^n$ ):

$$\mathbf{a} \cdot \mathbf{b}^T = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix} [5, 4, 7] = \begin{bmatrix} 1 \cdot 5 & 1 \cdot 4 & 1 \cdot 7 \\ 3 \cdot 5 & 3 \cdot 4 & 3 \cdot 7 \\ 5 \cdot 5 & 5 \cdot 4 & 5 \cdot 7 \end{bmatrix} = \begin{bmatrix} 5 & 4 & 7 \\ 15 & 12 & 21 \\ 25 & 20 & 35 \end{bmatrix}$$


- ❹ Wektor  $\mathbf{a}$  jest znormalizowany (jednostkowy) jeżeli jego długość (moduł) jest równy 1.  $\|\mathbf{a}\|_2 = 1$ .

## Operacje na wektorach - przykład

Wykorzystując iloczyn skalarny możemy wyznaczyć składową wektora w dowolnym kierunku. Projektja  $\mathbf{a}$  na kierunek  $\mathbf{i}_x$  jest liczona w następujący sposób:


$$\mathbf{a}_x = (\mathbf{a}^T \cdot \mathbf{i}_x) \mathbf{i}_x = ([3, 4] \cdot \begin{bmatrix} 1 \\ 0 \end{bmatrix}) [1, 0]^T = 3[1, 0]^T = [3, 0]^T \quad (2)$$

Zauważ, że  $\mathbf{i}_x$  to wektor jednostkowy:




## Operacje na wektorach - przykład

- Rozpatrzmy wektor  $\mathbf{a} = [3, 4, 1]^T$ . Obliczmy jego składową w kierunku  $\mathbf{i}_x = [1, 0, 0]^T$ . Zauważ, że  $\mathbf{i}_x$  to wektor jednostkowy.




## Operacje na wektorach - przykład

- Rozpatrzmy wektor  $\mathbf{a} = [3, 4, 1]^T$ . Obliczmy jego składową w kierunku  $\mathbf{i}_x = [1, 0, 0]^T$ . Zauważ, że  $\mathbf{i}_x$  to wektor jednostkowy.
- W tym celu wykonajmy iloczyn skalarny:  $\mathbf{a}^T \cdot \mathbf{i}_x = 3$ . Składowa wektora  $\mathbf{a}$  w kierunku  $\mathbf{i}_x$  jest równa:  $3\mathbf{i}_x = [3, 0, 0]$ .




## Operacje na wektorach - przykład

- Rozpatrzmy wektor  $\mathbf{a} = [3, 4, 1]^T$ . Obliczmy jego składową w kierunku  $\mathbf{i} = [-0.4364, 0.8729, -0.2182]^T$ . Zauważ, że  $\mathbf{i}$  to wektor jednostkowy.



## Operacje na wektorach - przykład

- Rozpatrzmy wektor  $\mathbf{a} = [3, 4, 1]^T$ . Obliczmy jego składową w kierunku  $\mathbf{i} = [-0.4364, 0.8729, -0.2182]^T$ . Zauważ, że  $\mathbf{i}$  to wektor jednostkowy.
- W tym celu wykonajmy iloczyn skalarny:  $\mathbf{a}^T \cdot \mathbf{i} = 1.9642$ . Składowa wektora  $\mathbf{a}$  w kierunku  $\mathbf{i}$  jest równa:  $1.9642\mathbf{i} = [-0.8572, 1.7146, -0.4286]$ .





## Operacje na wektorach - przykład

Zauważ, że powyższe (i kolejne) operacje są stosowane w  $n$ -wymiarowej przestrzeni ( $\mathbb{R}^n$ ). Rozpatrujemy jedynie  $\mathbb{R}^2$  i  $\mathbb{R}^3$  ze względu na możliwość wizualizacji wyników i jasnej interpretacji.

# Ortogonalność

- Para wektorów **a** i **b** jest ortogonalna, jeżeli

$$\mathbf{a}^T \mathbf{b} = 0$$

# Ortogonalność

- Para wektorów **a** i **b** jest ortogonalna, jeżeli

$$\mathbf{a}^T \mathbf{b} = 0$$

- Przykłady:

$$\mathbf{a}^T \cdot \mathbf{b} = [-14, 0, 0] \begin{bmatrix} 0 \\ 4 \\ 0 \end{bmatrix} = -14 \cdot 0 + 0 \cdot 4 + 0 \cdot 0 = 0$$

$$\mathbf{a}^T \cdot \mathbf{b} = [1, 3, 2] \begin{bmatrix} 5 \\ -3 \\ 2 \end{bmatrix} = 1 \cdot 5 + 3 \cdot (-3) + 2 \cdot 2 = 0$$

# Ortogonalność

- Para wektorów **a** i **b** jest ortogonalna, jeżeli

$$\mathbf{a}^T \mathbf{b} = 0$$

- Przykłady:



$$\mathbf{a}^T \cdot \mathbf{b} = [-14, 0, 0] \begin{bmatrix} 0 \\ 4 \\ 0 \end{bmatrix} = -14 \cdot 0 + 0 \cdot 4 + 0 \cdot 0 = 0$$

$$\mathbf{a}^T \cdot \mathbf{b} = [1, 3, 2] \begin{bmatrix} 5 \\ -3 \\ 2 \end{bmatrix} = 1 \cdot 5 + 3 \cdot (-3) + 2 \cdot 2 = 0$$

- Geometrycznie - wektory są **prostopadłe**.

# Ortogonalność - przykład

Wizualizacja poprzedniego przypadku:



## Ortogonalność (2)

- Dwie bazy  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2 \dots \mathbf{x}_n]$  and  $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2 \dots \mathbf{y}_m]$  są ortogonalne, jeżeli  $\mathbf{x}_i$  jest ortogonalny do  $\mathbf{y}_j$ , gdzie  $0 \leq i \leq n$  i  $0 \leq j \leq m$ .

## Ortogonalność (2)

- Dwie bazy  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2 \dots \mathbf{x}_n]$  and  $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2 \dots \mathbf{y}_m]$  są ortogonalne, jeżeli  $\mathbf{x}_i$  jest ortogonalny do  $\mathbf{y}_j$ , gdzie  $0 \leq i \leq n$  i  $0 \leq j \leq m$ .
- Baza  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2 \dots \mathbf{x}_n]$  jest ortogonalna, jeżeli jej wektory są parami ortogonalne

## Ortogonalność (2)

- Dwie bazy  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2 \dots \mathbf{x}_n]$  and  $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2 \dots \mathbf{y}_m]$  są ortogonalne, jeżeli  $\mathbf{x}_i$  jest ortogonalny do  $\mathbf{y}_j$ , gdzie  $0 \leq i \leq n$  i  $0 \leq j \leq m$ .
- Baza  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2 \dots \mathbf{x}_n]$  jest ortogonalna, jeżeli jej wektory są parami ortogonalne
- Baza jest **ortonormalna** jeżeli jest ortogonalna i składa się z wektorów jednostkowych:  $\|\mathbf{x}_i\|_2 = 1$ .



## Ortogonalność (2)

- Dwie bazy  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2 \dots \mathbf{x}_n]$  and  $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2 \dots \mathbf{y}_m]$  są ortogonalne, jeżeli  $\mathbf{x}_i$  jest ortogonalny do  $\mathbf{y}_j$ , gdzie  $0 \leq i \leq n$  i  $0 \leq j \leq m$ .
- Baza  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2 \dots \mathbf{x}_n]$  jest ortogonalna, jeżeli jej wektory są parami ortogonalne
- Baza jest **ortonormalna** jeżeli jest ortogonalna i składa się z wektorów jednostkowych:  $\|\mathbf{x}_i\|_2 = 1$ .
- Jeżeli baza  $\mathbf{X}$  jest ortonormalna, to:  $\mathbf{X}^T \cdot \mathbf{X} = \mathbf{I}$

## Ortogonalność (2)

- Dwie bazy  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2 \dots \mathbf{x}_n]$  and  $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2 \dots \mathbf{y}_m]$  są ortogonalne, jeżeli  $\mathbf{x}_i$  jest ortogonalny do  $\mathbf{y}_j$ , gdzie  $0 \leq i \leq n$  i  $0 \leq j \leq m$ .
- Baza  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2 \dots \mathbf{x}_n]$  jest ortogonalna, jeżeli jej wektory są parami ortogonalne
- Baza jest **ortonormalna** jeżeli jest ortogonalna i składa się z wektorów jednostkowych:  $\|\mathbf{x}_i\|_2 = 1$ .
- Jeżeli baza  $\mathbf{X}$  jest ortonormalna, to:  $\mathbf{X}^T \cdot \mathbf{X} = \mathbf{I}$ 
  - ponieważ  $\mathbf{x}_i^T \cdot \mathbf{x}_j = 1$  jedynie gdy  $i == j$ .

## Ortogonalność (2)

- Dwie bazy  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2 \dots \mathbf{x}_n]$  and  $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2 \dots \mathbf{y}_m]$  są ortogonalne, jeżeli  $\mathbf{x}_i$  jest ortogonalny do  $\mathbf{y}_j$ , gdzie  $0 \leq i \leq n$  i  $0 \leq j \leq m$ .
- Baza  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2 \dots \mathbf{x}_n]$  jest ortogonalna, jeżeli jej wektory są parami ortogonalne
- Baza jest **ortonormalna** jeżeli jest ortogonalna i składa się z wektorów jednostkowych:  $\|\mathbf{x}_i\|_2 = 1$ .
- Jeżeli baza  $\mathbf{X}$  jest ortonormalna, to:  $\mathbf{X}^T \cdot \mathbf{X} = \mathbf{I}$ 
  - ponieważ  $\mathbf{x}_i^T \cdot \mathbf{x}_j = 1$  jedynie gdy  $i == j$ .
  - W innym przypadku:  $\mathbf{x}_i^T \cdot \mathbf{x}_j = 0$

## Ortogonalność (2)

- Dwie bazy  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2 \dots \mathbf{x}_n]$  and  $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2 \dots \mathbf{y}_m]$  są ortogonalne, jeżeli  $\mathbf{x}_i$  jest ortogonalny do  $\mathbf{y}_j$ , gdzie  $0 \leq i \leq n$  i  $0 \leq j \leq m$ .
- Baza  $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2 \dots \mathbf{x}_n]$  jest ortogonalna, jeżeli jej wektory są parami ortogonalne
- Baza jest **ortonormalna** jeżeli jest ortogonalna i składa się z wektorów jednostkowych:  $\|\mathbf{x}_i\|_2 = 1$ .
- Jeżeli baza  $\mathbf{X}$  jest ortonormalna, to:  $\mathbf{X}^T \cdot \mathbf{X} = \mathbf{I}$ 
  - ponieważ  $\mathbf{x}_i^T \cdot \mathbf{x}_j = 1$  jedynie gdy  $i == j$ .
  - W innym przypadku:  $\mathbf{x}_i^T \cdot \mathbf{x}_j = 0$
  - W efekcie mamy 1 na diagonalu i 0 w pozostałych miejscach macierzy. Powstaje więc **Macierz jednostkowa**

# Ortogonalność - przykład

- Baza  $\mathbf{X}$  jest ortonormalna (zawiera 3 wektory z przestrzeni  $\mathbb{R}^4$ ):

$$\mathbf{X} = \begin{bmatrix} -0.5741 & -0.0549 & 0.1493 \\ -0.3714 & 0.8999 & -0.1449 \\ -0.5389 & -0.3895 & -0.6911 \\ -0.4920 & -0.1886 & 0.6922 \end{bmatrix}$$

## Ortogonalność - przykład

- Baza  $\mathbf{X}$  jest ortonormalna (zawiera 3 wektory z przestrzeni  $\mathbb{R}^4$ ):


$$\mathbf{X} = \begin{bmatrix} -0.5741 & -0.0549 & 0.1493 \\ -0.3714 & 0.8999 & -0.1449 \\ -0.5389 & -0.3895 & -0.6911 \\ -0.4920 & -0.1886 & 0.6922 \end{bmatrix}$$

- $\mathbf{X}^T \cdot \mathbf{X} = \mathbf{I}$

$$\mathbf{X}^T \cdot \mathbf{X} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$


## Ortogonalność (3)

- Innymi słowy, wektory z bazy **X** są liniowo niezależne (**linearly independent**) (!!!)



## Ortogonalność (3)

- Innymi słowy, wektory z bazy **X** są liniowo niezależne (**linearly independent**) (!!!)
- Dwa wektory są **liniowo zależne** jeżeli *wskazują ten sam kierunek*






## Ortogonalność (3)

- Innymi słowy, wektory z bazy **X** są liniowo niezależne (**linearly independent**) (!!!)
- Dwa wektory są **liniowo zależne** jeżeli *wskazują ten sam kierunek*
- Równoważnie, 2 wektory **a** i **b** są **liniowo zależne** jeżeli istnieje skalar  $c$ , taki że:

$$\mathbf{a} = c\mathbf{b} \quad (3)$$




## Ortogonalność (3)

- Innymi słowy, wektory z bazy **X** są liniowo niezależne (**linearly independent**) (!!!)
- Dwa wektory są **liniowo zależne** jeżeli *wskazują ten sam kierunek*
- Równoważnie, 2 wektory **a** i **b** są **liniowo zależne** jeżeli istnieje skalar  $c$ , taki że:

$$\mathbf{a} = c\mathbf{b} \quad (3)$$

- W przeciwnym przypadku wektory są **liniowo niezależne**.




## Ortogonalność (3)

- Innymi słowy, wektory z bazy **X** są liniowo niezależne (**linearly independent**) (!!!)
- Dwa wektory są **liniowo zależne** jeżeli *wskazują ten sam kierunek*
- Równoważnie, 2 wektory **a** i **b** są **liniowo zależne** jeżeli istnieje skalar  $c$ , taki że:

$$\mathbf{a} = c\mathbf{b} \quad (3)$$

- W przeciwnym przypadku wektory są **liniowo niezależne**.
- Przykład dwóch wektorów liniowo zależnych:



## Ortogonalność (4)

Bardziej ogólnie:

- Baza wektorów jest **liniowo zależna** jeżeli co najmniej jeden wektor z bazy może być przedstawiony jako **kombinacja liniowa** pozostałych:

$$\mathbf{x}_i = \sum_{k=1, k \neq i}^n c_k \mathbf{x}_k \quad (4)$$

gdzie  $c_i$  jest współczynnikiem.

## Ortogonalność (4)

Bardziej ogólnie:

- Baza wektorów jest **liniowo zależna** jeżeli co najmniej jeden wektor z bazy może być przedstawiony jako **kombinacja liniowa** pozostałych:

$$\mathbf{x}_i = \sum_{k=1, k \neq i}^n c_k \mathbf{x}_k \quad (4)$$

gdzie  $c_i$  jest współczynnikiem.

- rozpatrzmy 3 wektory:  $\mathbf{x}_1 = [1, 3, 2]$ ,  $\mathbf{x}_2 = [4, 1, 2]$ ,  $\mathbf{x}_3 = [6, 7, 6]$ .

## Ortogonalność (4)

Bardziej ogólnie:

- Baza wektorów jest **liniowo zależna** jeżeli co najmniej jeden wektor z bazy może być przedstawiony jako **kombinacja liniowa** pozostałych:

$$\mathbf{x}_i = \sum_{k=1, k \neq i}^n c_k \mathbf{x}_k \quad (4)$$

gdzie  $c_i$  jest współczynnikiem.

- rozpatrzmy 3 wektory:  $\mathbf{x}_1 = [1, 3, 2]$ ,  $\mathbf{x}_2 = [4, 1, 2]$ ,  $\mathbf{x}_3 = [6, 7, 6]$ .
- są one liniowo zależne, ponieważ:  $\mathbf{x}_3 = 2 \cdot \mathbf{x}_1 + 1 \cdot \mathbf{x}_2$

# Ortogonalność (4)

Bardziej ogólnie:

- Baza wektorów jest **liniowo zależna** jeżeli co najmniej jeden wektor z bazy może być przedstawiony jako **kombinacja liniowa** pozostałych:

$$\mathbf{x}_i = \sum_{k=1, k \neq i}^n c_k \mathbf{x}_k \quad (4)$$

gdzie  $c_i$  jest współczynnikiem.

- rozpatrzmy 3 wektory:  $\mathbf{x}_1 = [1, 3, 2]$ ,  $\mathbf{x}_2 = [4, 1, 2]$ ,  $\mathbf{x}_3 = [6, 7, 6]$ .
- są one liniowo zależne, ponieważ:  $\mathbf{x}_3 = 2 \cdot \mathbf{x}_1 + 1 \cdot \mathbf{x}_2$
- W przeciwnym przypadku są one **liniowo niezależne**.

# Ortogonalność (4)

Bardziej ogólnie:

- Baza wektorów jest **liniowo zależna** jeżeli co najmniej jeden wektor z bazy może być przedstawiony jako **kombinacja liniowa** pozostałych:

$$\mathbf{x}_i = \sum_{k=1, k \neq i}^n c_k \mathbf{x}_k \quad (4)$$

gdzie  $c_i$  jest współczynnikiem.

- rozpatrzmy 3 wektory:  $\mathbf{x}_1 = [1, 3, 2]$ ,  $\mathbf{x}_2 = [4, 1, 2]$ ,  $\mathbf{x}_3 = [6, 7, 6]$ .
- są one liniowo zależne, ponieważ:  $\mathbf{x}_3 = 2 \cdot \mathbf{x}_1 + 1 \cdot \mathbf{x}_2$
- W przeciwnym przypadku są one **liniowo niezależne**.
- Czy można przedstawić jeden z poniższych wektorów jako kombinację liniową pozostałych dwóch?  $\mathbf{x}_1 = [1, 0, 0]$ ,  $\mathbf{x}_2 = [0, 1, 0]$ ,  $\mathbf{x}_3 = [0, 0, 1]$



## Ortogonalność (4)

Bardziej ogólnie:

- Baza wektorów jest **liniowo zależna** jeżeli co najmniej jeden wektor z bazy może być przedstawiony jako **kombinacja liniowa** pozostałych:


$$\mathbf{x}_i = \sum_{k=1, k \neq i}^n c_k \mathbf{x}_k \quad (4)$$

gdzie  $c_i$  jest współczynnikiem.

- rozpatrzmy 3 wektory:  $\mathbf{x}_1 = [1, 3, 2]$ ,  $\mathbf{x}_2 = [4, 1, 2]$ ,  $\mathbf{x}_3 = [6, 7, 6]$ .
- są one liniowo zależne, ponieważ:  $\mathbf{x}_3 = 2 \cdot \mathbf{x}_1 + 1 \cdot \mathbf{x}_2$
- W przeciwnym przypadku są one **liniowo niezależne**.
- Czy można przedstawić jeden z poniższych wektorów jako kombinację liniową pozostałych dwóch?  $\mathbf{x}_1 = [1, 0, 0]$ ,  $\mathbf{x}_2 = [0, 1, 0]$ ,  $\mathbf{x}_3 = [0, 0, 1]$
- nie. Są one liniowo niezależne (ponadto, ortonormalne).


## Ortogonalność - przykład (5)

- Najważniejszy wniosek z tematów ortogonalności i iloczynu skalanego jest następujący: **iloczyn skłarny można wykorzystać do rozłożenia dowolnych wektorów na składowe ortogonalne.**




## Ortogonalność - przykład (5)

- Najważniejszy wniosek z tematów ortogonalności i iloczynu skalanego jest następujący: **iloczyn skłarny można wykorzystać do rozłożenia dowolnych wektorów na składowe ortogonalne.**
- Rozpatrzmy 3 ortonormalne wektory w przestrzeni  $\mathbb{R}^3$  :  
 $\mathbf{x}_1 = [1, 0, 0]^T$ ,  $\mathbf{x}_2 = [0, 1, 0]^T$ ,  $\mathbf{x}_3 = [0, 0, 1]^T$



## Ortogonalność - przykład (5)

- Najważniejszy wniosek z tematów ortogonalności i iloczynu skalanego jest następujący: **iloczyn skłarny można wykorzystać do rozłożenia dowolnych wektorów na składowe ortogonalne.**
- Rozpatrzmy 3 ortonormalne wektory w przestrzeni  $\mathbb{R}^3$  :  
 $\mathbf{x}_1 = [1, 0, 0]^T$ ,  $\mathbf{x}_2 = [0, 1, 0]^T$ ,  $\mathbf{x}_3 = [0, 0, 1]^T$
- Wektor  $\mathbf{a} = [3, -2, 4]^T$  może być rozłożony na 3 składowe:  
 $c_1 = \mathbf{a}^T \cdot \mathbf{x}_1 = 3$ ,  $c_2 = \mathbf{a}^T \cdot \mathbf{x}_2 = -2$ ,  $c_3 = \mathbf{a}^T \cdot \mathbf{x}_3 = 4$





## Ortogonalność - (dodatkowy) przykład (6)

- Podobnie,  $\mathbf{a} = [3, -2, 4, 6]^T$  może być rozłożony na 3 składowe, używając poniższej bazy, zawierającej 3 wektory:

## Ortogonalność - (dodatkowy) przykład (6)

- Podobnie,  $\mathbf{a} = [3, -2, 4, 6]^T$  może być rozłożony na 3 składowe, używając poniższej bazy, zawierającej 3 wektory:
- Baza ortonormalna  $\mathbf{X}$ :

$$\mathbf{X} = \begin{bmatrix} -0.5741 & -0.0549 & 0.1493 \\ -0.3714 & 0.8999 & -0.1449 \\ -0.5389 & -0.3895 & -0.6911 \\ -0.4920 & -0.1886 & 0.6922 \end{bmatrix}$$

## Ortogonalność - (dodatkowy) przykład (6)

- Podobnie,  $\mathbf{a} = [3, -2, 4, 6]^T$  może być rozłożony na 3 składowe, używając poniższej bazy, zawierającej 3 wektory:
- Baza ortonormalna  $\mathbf{X}$ :

$$\mathbf{X} = \begin{bmatrix} -0.5741 & -0.0549 & 0.1493 \\ -0.3714 & 0.8999 & -0.1449 \\ -0.5389 & -0.3895 & -0.6911 \\ -0.4920 & -0.1886 & 0.6922 \end{bmatrix}$$

- Obliczamy współczynniki:  $\mathbf{c} = [c_1, c_2, c_3]^T = \mathbf{a}^T \mathbf{X} = [-6.0871, -4.6541, 2.1265]$



## Ortogonalność - (dodatkowy) przykład (6)

- Podobnie,  $\mathbf{a} = [3, -2, 4, 6]^T$  może być rozłożony na 3 składowe, używając poniższej bazy, zawierającej 3 wektory:
- Baza ortonormalna  $\mathbf{X}$ :

$$\mathbf{X} = \begin{bmatrix} -0.5741 & -0.0549 & 0.1493 \\ -0.3714 & 0.8999 & -0.1449 \\ -0.5389 & -0.3895 & -0.6911 \\ -0.4920 & -0.1886 & 0.6922 \end{bmatrix}$$

- Obliczamy współczynniki:  $\mathbf{c} = [c_1, c_2, c_3]^T = \mathbf{a}^T \mathbf{X} = [-6.0871, -4.6541, 2.1265]$
- Wektor  $\mathbf{a}$  może być przybliżony za pomocą:  $\mathbf{a} \approx \mathbf{X}\mathbf{c}$

# SVD (1)

① Rozpatrzmy macierz  $\mathbf{A} \in \mathbb{R}^{2 \times 2}$  i trzy wektory:  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3 \in \mathbb{R}^2$  o normie  $\|\mathbf{a}_i\|_2 = 1$ :

# SVD (1)

① Rozpatrzmy macierz  $\mathbf{A} \in \mathbb{R}^{2 \times 2}$  i trzy wektory:  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3 \in \mathbb{R}^2$  o normie  $\|\mathbf{a}_i\|_2 = 1$ :

- $\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -3 & 2 \end{bmatrix}$

# SVD (1)

❶ Rozpatrzmy macierz  $\mathbf{A} \in \mathbb{R}^{2 \times 2}$  i trzy wektory:  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3 \in \mathbb{R}^2$  o normie  $\|\mathbf{a}_i\|_2 = 1$ :

- $\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -3 & 2 \end{bmatrix}$
- $\mathbf{a}_1 = \begin{bmatrix} 1 & 0 \end{bmatrix}^T$

# SVD (1)

❶ Rozpatrzmy macierz  $\mathbf{A} \in \mathbb{R}^{2 \times 2}$  i trzy wektory:  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3 \in \mathbb{R}^2$  o normie  $\|\mathbf{a}_i\|_2 = 1$ :

- $\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -3 & 2 \end{bmatrix}$
- $\mathbf{a}_1 = \begin{bmatrix} 1 & 0 \end{bmatrix}^T$
- $\mathbf{a}_2 = \begin{bmatrix} \sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix}^T$

# SVD (1)

① Rozpatrzmy macierz  $\mathbf{A} \in \mathbb{R}^{2 \times 2}$  i trzy wektory:  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3 \in \mathbb{R}^2$  o normie  $\|\mathbf{a}_i\|_2 = 1$ :

- $\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -3 & 2 \end{bmatrix}$
- $\mathbf{a}_1 = \begin{bmatrix} 1 & 0 \end{bmatrix}^T$
- $\mathbf{a}_2 = \begin{bmatrix} \sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix}^T$
- $\mathbf{a}_3 = \begin{bmatrix} 0 & 1 \end{bmatrix}^T$

# SVD (1)

① Rozpatrzmy macierz  $\mathbf{A} \in \mathbb{R}^{2 \times 2}$  i trzy wektory:  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3 \in \mathbb{R}^2$  o normie  $\|\mathbf{a}_i\|_2 = 1$ :

- $\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -3 & 2 \end{bmatrix}$
- $\mathbf{a}_1 = \begin{bmatrix} 1 & 0 \end{bmatrix}^T$
- $\mathbf{a}_2 = \begin{bmatrix} \sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix}^T$
- $\mathbf{a}_3 = \begin{bmatrix} 0 & 1 \end{bmatrix}^T$

② Przemnażając wektory  $\mathbf{x}_i$  przez macierz  $\mathbf{A}$ , otrzymujemy:

# SVD (1)

① Rozpatrzmy macierz  $\mathbf{A} \in \mathbb{R}^{2 \times 2}$  i trzy wektory:  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3 \in \mathbb{R}^2$  o normie  $\|\mathbf{a}_i\|_2 = 1$ :

- $\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -3 & 2 \end{bmatrix}$
- $\mathbf{a}_1 = \begin{bmatrix} 1 & 0 \end{bmatrix}^T$
- $\mathbf{a}_2 = \begin{bmatrix} \sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix}^T$
- $\mathbf{a}_3 = \begin{bmatrix} 0 & 1 \end{bmatrix}^T$

② Przemnażając wektory  $\mathbf{x}_i$  przez macierz  $\mathbf{A}$ , otrzymujemy:

- $\mathbf{b}_1 = \mathbf{A}\mathbf{x}_1 = \begin{bmatrix} 1 & -3 \end{bmatrix}^T$



# SVD (1)

① Rozpatrzmy macierz  $\mathbf{A} \in \mathbb{R}^{2 \times 2}$  i trzy wektory:  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3 \in \mathbb{R}^2$  o normie  $\|\mathbf{a}_i\|_2 = 1$ :

- $\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -3 & 2 \end{bmatrix}$

- $\mathbf{a}_1 = \begin{bmatrix} 1 & 0 \end{bmatrix}^T$

- $\mathbf{a}_2 = \begin{bmatrix} \sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix}^T$

- $\mathbf{a}_3 = \begin{bmatrix} 0 & 1 \end{bmatrix}^T$

② Przemnażając wektory  $\mathbf{x}_i$  przez macierz  $\mathbf{A}$ , otrzymujemy:

- $\mathbf{b}_1 = \mathbf{A}\mathbf{x}_1 = \begin{bmatrix} 1 & -3 \end{bmatrix}^T$

- $\mathbf{b}_2 = \mathbf{A}\mathbf{x}_2 = \begin{bmatrix} 3.53553 & -0.70711 \end{bmatrix}^T$

# SVD (1)

① Rozpatrzmy macierz  $\mathbf{A} \in \mathbb{R}^{2 \times 2}$  i trzy wektory:  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3 \in \mathbb{R}^2$  o normie  $\|\mathbf{a}_i\|_2 = 1$ :

- $\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -3 & 2 \end{bmatrix}$
- $\mathbf{a}_1 = \begin{bmatrix} 1 & 0 \end{bmatrix}^T$
- $\mathbf{a}_2 = \begin{bmatrix} \sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix}^T$
- $\mathbf{a}_3 = \begin{bmatrix} 0 & 1 \end{bmatrix}^T$

② Przemnażając wektory  $\mathbf{x}_i$  przez macierz  $\mathbf{A}$ , otrzymujemy:

- $\mathbf{b}_1 = \mathbf{A}\mathbf{x}_1 = \begin{bmatrix} 1 & -3 \end{bmatrix}^T$
- $\mathbf{b}_2 = \mathbf{A}\mathbf{x}_2 = \begin{bmatrix} 3.53553 & -0.70711 \end{bmatrix}^T$
- $\mathbf{b}_3 = \mathbf{A}\mathbf{x}_3 = \begin{bmatrix} 4 & 2 \end{bmatrix}^T$

# SVD (1)

① Rozpatrzmy macierz  $\mathbf{A} \in \mathbb{R}^{2 \times 2}$  i trzy wektory:  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3 \in \mathbb{R}^2$  o normie  $\|\mathbf{a}_i\|_2 = 1$ :

- $\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -3 & 2 \end{bmatrix}$
- $\mathbf{a}_1 = \begin{bmatrix} 1 & 0 \end{bmatrix}^T$
- $\mathbf{a}_2 = \begin{bmatrix} \sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix}^T$
- $\mathbf{a}_3 = \begin{bmatrix} 0 & 1 \end{bmatrix}^T$

② Przemnażając wektory  $\mathbf{x}_i$  przez macierz  $\mathbf{A}$ , otrzymujemy:

- $\mathbf{b}_1 = \mathbf{A}\mathbf{x}_1 = \begin{bmatrix} 1 & -3 \end{bmatrix}^T$
- $\mathbf{b}_2 = \mathbf{A}\mathbf{x}_2 = \begin{bmatrix} 3.53553 & -0.70711 \end{bmatrix}^T$
- $\mathbf{b}_3 = \mathbf{A}\mathbf{x}_3 = \begin{bmatrix} 4 & 2 \end{bmatrix}^T$

③ Normy wektorów  $\mathbf{y}_1$  wynoszą:

# SVD (1)

❶ Rozpatrzmy macierz  $\mathbf{A} \in \mathbb{R}^{2 \times 2}$  i trzy wektory:  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3 \in \mathbb{R}^2$  o normie  $\|\mathbf{a}_i\|_2 = 1$ :

- $\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -3 & 2 \end{bmatrix}$
- $\mathbf{a}_1 = \begin{bmatrix} 1 & 0 \end{bmatrix}^T$
- $\mathbf{a}_2 = \begin{bmatrix} \sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix}^T$
- $\mathbf{a}_3 = \begin{bmatrix} 0 & 1 \end{bmatrix}^T$

❷ Przemnażając wektory  $\mathbf{x}_i$  przez macierz  $\mathbf{A}$ , otrzymujemy:

- $\mathbf{b}_1 = \mathbf{A}\mathbf{x}_1 = \begin{bmatrix} 1 & -3 \end{bmatrix}^T$
- $\mathbf{b}_2 = \mathbf{A}\mathbf{x}_2 = \begin{bmatrix} 3.53553 & -0.70711 \end{bmatrix}^T$
- $\mathbf{b}_3 = \mathbf{A}\mathbf{x}_3 = \begin{bmatrix} 4 & 2 \end{bmatrix}^T$

❸ Normy wektorów  $\mathbf{y}_1$  wynoszą:

- $\|\mathbf{b}_1\|_2 = 3.1623$

# SVD (1)

① Rozpatrzmy macierz  $\mathbf{A} \in \mathbb{R}^{2 \times 2}$  i trzy wektory:  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3 \in \mathbb{R}^2$  o normie  $\|\mathbf{a}_i\|_2 = 1$ :

- $\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -3 & 2 \end{bmatrix}$
- $\mathbf{a}_1 = \begin{bmatrix} 1 & 0 \end{bmatrix}^T$
- $\mathbf{a}_2 = \begin{bmatrix} \sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix}^T$
- $\mathbf{a}_3 = \begin{bmatrix} 0 & 1 \end{bmatrix}^T$

② Przemnażając wektory  $\mathbf{x}_i$  przez macierz  $\mathbf{A}$ , otrzymujemy:

- $\mathbf{b}_1 = \mathbf{A}\mathbf{x}_1 = \begin{bmatrix} 1 & -3 \end{bmatrix}^T$
- $\mathbf{b}_2 = \mathbf{A}\mathbf{x}_2 = \begin{bmatrix} 3.53553 & -0.70711 \end{bmatrix}^T$
- $\mathbf{b}_3 = \mathbf{A}\mathbf{x}_3 = \begin{bmatrix} 4 & 2 \end{bmatrix}^T$

③ Normy wektorów  $\mathbf{y}_1$  wynoszą:

- $\|\mathbf{b}_1\|_2 = 3.1623$
- $\|\mathbf{b}_2\|_2 = 3.6056$

# SVD (1)

① Rozpatrzmy macierz  $\mathbf{A} \in \mathbb{R}^{2 \times 2}$  i trzy wektory:  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3 \in \mathbb{R}^2$  o normie  $\|\mathbf{a}_i\|_2 = 1$ :

- $\mathbf{A} = \begin{bmatrix} 1 & 4 \\ -3 & 2 \end{bmatrix}$
- $\mathbf{a}_1 = \begin{bmatrix} 1 & 0 \end{bmatrix}^T$
- $\mathbf{a}_2 = \begin{bmatrix} \sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix}^T$
- $\mathbf{a}_3 = \begin{bmatrix} 0 & 1 \end{bmatrix}^T$

② Przemnażając wektory  $\mathbf{x}_i$  przez macierz  $\mathbf{A}$ , otrzymujemy:


- $\mathbf{b}_1 = \mathbf{A}\mathbf{x}_1 = \begin{bmatrix} 1 & -3 \end{bmatrix}^T$
- $\mathbf{b}_2 = \mathbf{A}\mathbf{x}_2 = \begin{bmatrix} 3.53553 & -0.70711 \end{bmatrix}^T$
- $\mathbf{b}_3 = \mathbf{A}\mathbf{x}_3 = \begin{bmatrix} 4 & 2 \end{bmatrix}^T$

③ Normy wektorów  $\mathbf{y}_1$  wynoszą:

- $\|\mathbf{b}_1\|_2 = 3.1623$
- $\|\mathbf{b}_2\|_2 = 3.6056$
- $\|\mathbf{b}_3\|_2 = 4.4721$


# SVD (2)

Trzy wektory:  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3 \in \mathbb{R}^2$  ( $\|\mathbf{a}_i\|_2 = 1$ )



# SVD (3)


Wektory  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3$  przemnożone przez  $\mathbf{A}$ :






# SVD (4)

Działanie macierzy  $\mathbf{A}$  na okrąg jednostkowy (z wykorzystaniem 2-normy):




# SVD (5)

Działanie macierzy  $\mathbf{B} = \begin{bmatrix} 1 & 4 \\ -3 & -2 \end{bmatrix}$  na okrąg jednostkowy (z wykorzystaniem 2-normy):



# SVD (6)

Działanie macierzy  $\mathbf{C} \in \mathbb{R}^{3 \times 3}$  na *kulę jednostkową (unit sphere)*



# SVD (7)

① Ponownie rozpatrzmy macierz  $\mathbf{B} \in \mathbb{R}^{2 \times 2}$ :

# SVD (7)

① Ponownie rozpatrzmy macierz  $\mathbf{B} \in \mathbb{R}^{2 \times 2}$ :

② 
$$\mathbf{B} = \begin{bmatrix} 1 & 4 \\ -3 & -2 \end{bmatrix}$$

# SVD (7)

① Ponownie rozpatrzmy macierz  $\mathbf{B} \in \mathbb{R}^{2 \times 2}$ :

② 
$$\mathbf{B} = \begin{bmatrix} 1 & 4 \\ -3 & -2 \end{bmatrix}$$

③ istnieje wektor jednostkowy:  $\mathbf{v}_1 = [-0.5257, -0.8507]^T$ , który, przemnożony przez  $\mathbf{B}$  daje:

$$\mathbf{B} \cdot \mathbf{v}_1 = \begin{bmatrix} -3.9283 \\ 3.2785 \end{bmatrix} = 5.1167 \cdot \begin{bmatrix} -0.7678 \\ 0.6407 \end{bmatrix} = \sigma_1 \mathbf{u}_1$$

# SVD (7)

❶ Ponownie rozpatrzmy macierz  $\mathbf{B} \in \mathbb{R}^{2 \times 2}$ :

❷  $\mathbf{B} = \begin{bmatrix} 1 & 4 \\ -3 & -2 \end{bmatrix}$

❸ istnieje wektor jednostkowy:  $\mathbf{v}_1 = [-0.5257, -0.8507]^T$ , który, przemnożony przez  $\mathbf{B}$  daje:

$$\mathbf{B} \cdot \mathbf{v}_1 = \begin{bmatrix} -3.9283 \\ 3.2785 \end{bmatrix} = 5.1167 \cdot \begin{bmatrix} -0.7678 \\ 0.6407 \end{bmatrix} = \sigma_1 \mathbf{u}_1$$

❹ Jeżeli rozpatrzmy wszystkie wektory z przestrzeni  $\mathbb{R}^2$ , okaże się, że w wyniku przemnożenia przez  $\mathbf{B}$  norma wektora  $\mathbf{v}_1$  wzrasta najbardziej.

# SVD (7)

- ① Ponownie rozpatrzmy macierz  $\mathbf{B} \in \mathbb{R}^{2 \times 2}$ :

② 
$$\mathbf{B} = \begin{bmatrix} 1 & 4 \\ -3 & -2 \end{bmatrix}$$

- ③ istnieje wektor jednostkowy:  $\mathbf{v}_1 = [-0.5257, -0.8507]^T$ , który, przemnożony przez  $\mathbf{B}$  daje:

$$\mathbf{B} \cdot \mathbf{v}_1 = \begin{bmatrix} -3.9283 \\ 3.2785 \end{bmatrix} = 5.1167 \cdot \begin{bmatrix} -0.7678 \\ 0.6407 \end{bmatrix} = \sigma_1 \mathbf{u}_1$$

- ④ Jeżeli rozpatrzmy wszystkie wektory z przestrzeni  $\mathbb{R}^2$ , okaże się, że w wyniku przemnożenia przez  $\mathbf{B}$  norma wektora  $\mathbf{v}_1$  wzrasta najbardziej.
- ⑤ wektor o długości 1 w wyniku przemnożenia daje wektor o normie  $\sigma_1 = 5.1167$ .



# SVD (7)

❶ Ponownie rozpatrzmy macierz  $\mathbf{B} \in \mathbb{R}^{2 \times 2}$ :

❷ 
$$\mathbf{B} = \begin{bmatrix} 1 & 4 \\ -3 & -2 \end{bmatrix}$$

❸ istnieje wektor jednostkowy:  $\mathbf{v}_1 = [-0.5257, -0.8507]^T$ , który, przemnożony przez  $\mathbf{B}$  daje:

$$\mathbf{B} \cdot \mathbf{v}_1 = \begin{bmatrix} -3.9283 \\ 3.2785 \end{bmatrix} = 5.1167 \cdot \begin{bmatrix} -0.7678 \\ 0.6407 \end{bmatrix} = \sigma_1 \mathbf{u}_1$$

❹ Jeżeli rozpatrzmy wszystkie wektory z przestrzeni  $\mathbb{R}^2$ , okaże się, że w wyniku przemnożenia przez  $\mathbf{B}$  norma wektora  $\mathbf{v}_1$  wzrasta najbardziej.

❺ wektor o długości 1 w wyniku przemnożenia daje wektor o normie  $\sigma_1 = 5.1167$ .

❻ jest to pierwsza (największa) wartość szczególna.

## Koło naukowe

- ① Aplikacja mobilna wspierająca pracę lekarzy (we współpracy z GUMed i szpitalem im. M. Płazyńskiego). (Splajny)

# Koło naukowe

- 1 Aplikacja mobilna wspierająca pracę lekarzy (we współpracy z GUMed i szpitalem im. M. Płazyńskiego). (Splajny)
- 2 Aplikacja mobilna wykorzystująca rzeczywistość rozszerzoną do wizualizacji rozkładu pola elektromagnetycznego w wybranych strukturach.

# Koło naukowe

- 1 Aplikacja mobilna wspierająca pracę lekarzy (we współpracy z GUMed i szpitalem im. M. Płazyńskiego). (Splajny)
- 2 Aplikacja mobilna wykorzystująca rzeczywistość rozszerzoną do wizualizacji rozkładu pola elektromagnetycznego w wybranych strukturach.
- 3 Analiza czułościowa wykorzystująca metoda Monte Carlo w symulacjach układów elektronicznych, działających na wysokich częstotliwościach.

# Koło naukowe

- 1 Aplikacja mobilna wspierająca pracę lekarzy (we współpracy z GUMed i szpitalem im. M. Płazyńskiego). (Splajny)
- 2 Aplikacja mobilna wykorzystująca rzeczywistość rozszerzoną do wizualizacji rozkładu pola elektromagnetycznego w wybranych strukturach.
- 3 Analiza czułościowa wykorzystująca metoda Monte Carlo w symulacjach układów elektronicznych, działających na wysokich częstotliwościach.
- 4 Metody optymalizacji, w symulacjach układów elektronicznych, działających na wysokich częstotliwościach.

# Koło naukowe

- 1 Aplikacja mobilna wspierająca pracę lekarzy (we współpracy z GUMed i szpitalem im. M. Płazyńskiego). (Splajny)
- 2 Aplikacja mobilna wykorzystująca rzeczywistość rozszerzoną do wizualizacji rozkładu pola elektromagnetycznego w wybranych strukturach.
- 3 Analiza czułościowa wykorzystująca metoda Monte Carlo w symulacjach układów elektronicznych, działających na wysokich częstotliwościach.
- 4 Metody optymalizacji, w symulacjach układów elektronicznych, działających na wysokich częstotliwościach.
- 5 Toolbox w matlabie do analizy sygnałów EEG.

# Koło naukowe

- 1 Aplikacja mobilna wspierająca pracę lekarzy (we współpracy z GUMed i szpitalem im. M. Płazyńskiego). (Splajny)
- 2 Aplikacja mobilna wykorzystująca rzeczywistość rozszerzoną do wizualizacji rozkładu pola elektromagnetycznego w wybranych strukturach.
- 3 Analiza czułościowa wykorzystująca metoda Monte Carlo w symulacjach układów elektronicznych, działających na wysokich częstotliwościach.
- 4 Metody optymalizacji, w symulacjach układów elektronicznych, działających na wysokich częstotliwościach.
- 5 Toolbox w matlabie do analizy sygnałów EEG.
- 6 Strona koła.